

Kirli veriyi temizlemek için LLM mi lazım, yoksa kurallar yeter mi?

10.000 sipariş, 15 bozma türü, hücre hücre ölçüm. Bu bölümde yalnızca LLM kullanmayan kural yöntemi var.

%97,6

bozuk hücrelerde doğru düzeltme

11 / 1.617

uydurma (bilinmeyen değere değer yazma)

0.990

müşteri eşleştirme F1

8 sn · \$0

süre ve maliyet

Deney nasıl kuruldu?

Bir Türk e-ticaret sitesini taklit eden sentetik veri ürettim: 2.500 müşteri, 300 ürün, 10.000 sipariş. Önce veri temiz üretildi ve saklandı. Sonra bilerek bozuldu: tarihler beş ayrı biçimde yazıldı, Türkçe karakterler bozuldu, fiyatlara TL ve ₺ işaretleri eklendi, müşteriler farklı yazımlarla tekrarlandı, kargo firmaları kısaltıldı, bazı satırlar birbirine yapıştı. Toplam 20.352 hücre bozuldu ve her bozma kaydedildi.

Temizleme sonucu saklanan temiz veriyle karşılaştırıldı. Bu yüzden "iyi görünüyor" demek yerine her hata türü için kesin bir oran verebiliyorum.

Neyi ölçtüm?

- **Doğru düzeltme:** Kurtarılabılır bozuk hücrelerin (19.271 hücre) yüzde kaçını gerçek değerine döndü.
- **Uydurma:** Gerçek değeri bilinmeyen hücreler var. Örneğin 2036 tarihli bir siparişin gerçek tarihi veriden çıkarılamaz. Doğru davranış bu hücreyi boş bırakmaktır. Oraya yazılan her yanlış değer uydurma sayıldı.
- **Temiz hücreyi bozma:** Zaten doğru olan 113.348 hücreden kaçını temizlik sırasında bozuldu. Sonuç: %0.
- **Müşteri eşleştirme:** Aynı kişinin tekrarlanan kayıtları bulunup birleştirildi mi?

Bu sonucu okurken: Bozmaları da kuralları da aynı kişi yazdı. Bu yüzden kural yöntemi burada gerçek hayatta olacağından daha iyi görünüyor. Gerçekte kural yazan kişi hataların hepsini önceden görmez. Asıl soru, LLM'in kuralın takıldığı yerleri değer uydurmadan kapatıp kapatamayacağı. Bu, 2. bölümün konusu.

Hangi hata ne kadar düzeldi?

LLM olmadan, sadece kurallarla: hangi hata ne kadar düzeldi?

10.000 sipariş · 15 bozma türü · doğru düzeltilen bozuk hücre oranı

HATA TÜRÜ	HÜCRE	KURAL	
Yazım tutarsızlığı B8	3.603		%89,5
Tekrarlanan müşteri B1	163		%92,6
Karışık tarih formatı B3	5.425		%98,8
Bozuk Türkçe karakter B4	228		%99,1
Sayı ve para formatı B6	5.946		%99,9
Boşluk / görünmez karakter B11	997		%100
Telefon formatı B9	618		%100
Eksik değer B5	606		%100
Karışık birim ve tip B15	599		%100
ID format kayması B13	528		%100
Tutarsız toplam B12	234		%100
Tekrarlanan sipariş B2	204		%100
Geçersiz değer B7	184		%100
Bozuk e-posta B10	140		%100
Kaymış / bozuk satır B14	133		%100

%97,6

genel doğru düzeltme

%0,7

uydurma

8 sn

süre

\$0

maliyet

Sentetik veri, seed 42

github.com/sefa05/Claude-veri-temizleme-

Gerçek örnekler

Kirli veri, kuralların elinden geçince

Gerçek örnekler · LLM yok · sentetik e-ticaret verisi

✓ DÜZELTTİ

dogum_tarihi	24-Oct-1959	→	1959-10-24
soyad	YÄ±ldÄ±z	→	Yıldız
ad	Ay?e	→	Ayşe
birim_fiyat	₺4,851.99	→	4851.99
eposta	orhan.isikgmail.com	→	orhan.isik@gmail.com
il	SAM.	→	Samsun
adet	dört	→	4
adet	-3	→	3 (toplamdan doğrulandı)
toplam_tutar	1135.10	→	113.51 (yeniden hesaplandı)

– DOĞRU OLANI YAPTI: UYDURMADI

siparis_tarihi	2036-01-11	→	boş bıraktı (gelecek tarih, gerçeği bilinemez)
----------------	------------	---	--

✗ YAPAMADI

kargo_firmasi	TEX	→	boş gerçek: Trendyol Express
odeme_yontemi	Papara	→	boş gerçek: Dijital Cüzdan
durum	Tamamlandı	→	boş gerçek: Teslim Edildi
dogum_tarihi	06/01/1967	→	1967-01-06 gerçek: 1967-06-01

Sıradaki soru: LLM bunları uydurmadan çözebilir mi?

github.com/sefa05/Claude-veri-temizleme-

Kural nerede takıldı?

Sorun	Örnek	Sonuç
Sözlükte olmayan kısaltma ve eş anlamlılar	TEX , YK , Papara , Tamamlandı	%89,5 doğru, kalanı boş
Gün/ay sırası belirsiz tarih	06/01/1967 : 6 Ocak mı, 1 Haziran mı?	%98,8 doğru
Kanıtı zayıf müşteri çiftleri	Doğum tarihi bozuk, telefon yok, sadece ilçe ve e-posta benziyor	159 çiftten 156'sı bulundu

Kural bilmediği bir değerle karşılaşınca tahmin etmiyor, hücreyi boş bırakıyor. Bu yüzden hata yaptığı yerlerin çoğunda yanlış değer değil boşluk üretiyor. Müşteri eşleştirmede de hiç yanlış eşleşme yapmadı.

Gerçeği bilinemeyen hücrelerde ne yaptı?

1.081 kurtarılamaz hücrenin %97,7'ini boş bıraktı, %1'ine yanlış değer yazdı, %1,3'inde tahmini tuttu.

Yapısal işler

- 133 bozuk satırın hepsi kurtarıldı (; ayraçlı, fazladan alanlı, birbirine yapışmış satırlar).
- 258 tekrar sipariş satırı silindi, 136 tekrar müşteri kaydı birleştirildi.

Veri seti açık: sen de dene

Kirli veri, cevap anahtarı ve puanlama aracı repoda. Veriyi istediğin yöntemle (kural, LLM, ajan ya da elle) temizle, tek komutla skorunu al:

```
git clone https://github.com/sefa05/Claude-veri-temizleme-  
pip install -e .  
veri-temizle puanla benim_ciktim/
```

Her hata türü için ayrı puan, uydurma sayısı ve müşteri eşleştirme skoru çıkar. Beklenen çıktı biçimi `veri_seti/README.md` dosyasında. Kural yöntemi %97,6 yaptı. Geçebilir misin?

Sıradaki: 2. bölüm

Aynı veri iki yöntemle daha temizlenecek:

- Sadece LLM:** Ham satırlar Claude'a gidiyor, model temiz kaydı döndürüyor.
- Hibrit:** Önce kural çalışıyor, çözemediği hücreler LLM'e soruluyor. Model il ve seçenek alanlarında serbest yazmıyor, referans listeden çekilen adaylar arasından seçiyor.

Doğruluk, uydurma, maliyet ve süre yan yana karşılaştırılacak.

Kod, veri ve yöntem: github.com/sefa05/Claude-veri-temizleme- · Veri tamamen sentetiktir, gerçek kişilere ait değildir.