

Kurallarım %97,6 yaptı. Görmediği hatalarla test edince ne oldu?

Aynı veri, aynı kod, yeni hata biçimleri. Kural yöntemi %97,6 → %68,9.

%97,6 → %68,9

bozuk hücrelerde doğru
düzeltme

11 → 31

uydurma (bilinmeyen
değere değer yazma)

0 → 123

kaybolan sipariş

0

değişen kod satırı

1. bölümün açığı

1. bölümde kural tabanlı temizleyici 10.000 siparişlik kirli verinin bozuk hücrelerini %97,6 oranında doğru düzeltti. Ama bir sorun vardı: hataları da kuralları da aynı kişi yazdı. Kural, hangi hatayla karşılaşacağını önceden biliyordu. Gerçek hayatta böyle olmaz.

Bu bölümde ne değişti?

- Kural kodu donduruldu.** Temizleme kodu `60d97ad` commit'indeki haliyle kaldı, tek satırına dokunulmadı.
- Temiz veri aynı.** Aynı 2.500 müşteri, 300 ürün, 10.000 sipariş.
- Hata türleri aynı, biçimleri yeni.** 15 hata türünün her biri gerçek hayatta görülen başka biçimlerle geldi: `27 Şubat 1987 Cuma`, Unix zamanı, Excel tarih numarası, `ayse[at]gmail.com`, `MUS-00211`, `81 TL 62 kr`, HTML karakter kodları, sekmeye ayrılmış satırlar, görünmez `\r` karakteri.
- Hepsi kurtarılabilir.** Yalnızca gerçek değeri kirli metinden kesin olarak çıkarılabilen biçimler seçildi. Sonuç düşünün diye bilerek belirsiz veri üretilmedi.

Dürüstlük notu: Yeni biçimleri de ben seçtim ve kural kodunu biliyordum. Bu test kuralı zorlamaya yönelik bir stres testidir. Gerçek bir veri kaynağındaki düşüş daha az ya da daha fazla olabilir. Ölçülen şey şu: kurallar yazıldıkları dünyanın dışına çıkınca ne kadar ve nasıl kırılıyor?

Hangi hata türünde ne kadar düştü?

Aynı kurallar, görmediği hatalar

10.000 sipariş · kod değişmedi · doğru düzeltilen bozuk hücre oranı

HATA TÜRÜ	HÜCRE	BİLİNEREN HATALAR	GÖRMEYİŞİ HATALAR
ID format kayması B13	528	%100	%20,5
Bozuk e-posta B10	140	%100	%30,1
Karışık tarih formatı B3	5.425	%98,8	%32,1
Kaymış / bozuk satır B14	133	%100	%46,4
Bozuk Türkçe karakter B4	228	%99,1	%50,7
Yazım tutarsızlığı B8	3.603	%89,5	%78,6
Karışık birim ve tip B15	599	%100	%81,8
Tutarsız toplam B12	234	%100	%83,6
Tekrarlanan müşteri B1	163	%92,6	%85,9
Geçersiz değer B7	184	%100	%86
Boşluk / görünmez karakter B11	997	%100	%88,5
Eksik değer B5	606	%100	%88,6
Sayı ve para formatı B6	5.946	%99,9	%91,4
Tekrarlanan sipariş B2	204	%100	%97,5
Telefon formatı B9	618	%100	%98,5

%97,6 → %68,9

genel doğru düzeltme

11 → 31

uydurma

%100 → %46,4

bozuk satır kurtarma

0

değişen kod satırı

Sentetik veri, seed 42

github.com/sefa05/Claude-veri-temizleme-

Gerçek örnekler

Kurallar görmediği hatayla karşılaşınca

Gerçek örnekler · kural kodu değişmedi · sentetik e-ticaret verisi

✓ HÂLÂ DÜZELTTİ

kargo_firmasi	Yurtici Krg	→	Yurtiçi Kargo
durum	Delivered	→	Teslim Edildi
birim_fiyat	81 TL 62 kr	→	81.62
il	İstanbul/Sarıyer	→	İstanbul

⊖ SESSİZCE BOŞ BIRAKTI gerçek değer belliydi

dogum_tarihi	27 Şubat 1987 Cuma	→	boş gerçek: 1987-02-27
dogum_tarihi	1105920000	→	boş gerçek: 2005-01-17 (Unix zamanı)
musteri_id	MUS-00211	→	boş gerçek: M00211
kargo_firmasi	TY Express	→	boş gerçek: Trendyol Express

✗ GÜVENLE YANLIŞ YAZDI

ad	Yağmur	→	Yağmur gerçek: Yağmur
ad	Ă...Ă%eyma	→	Ăzeyma gerçek: Şeyma
ad	Ba_ak	→	Ba_ak gerçek: Başak

! SATIRI KAYBETTİ toplam 123 sipariş

satır	S000015-M01692-U0206-M...	→	satır kayboldu gerçek: sekmeye ayrılmış satır
durum	Teslim Edildi _ç	→	satır kayboldu gerçek: gizli \r satırı ikiye böldü

Veri seti açık: sen de dene

github.com/sefa05/Claude-veri-temizleme-

Dersler

- Kurallar bilinen dünyada çok iyi, yeni biçimde kırılğan.** Aynı kod, aynı hata türlerinin başka yazımlarında %97,6 → %68,9 düştü. En sert düşüşler ID biçimi (%100 → %20,5), e-posta (%100 → %30,1) ve tarihlerde (%98,8 → %32,1) oldu.
- Kırılma çoğunlukla sessiz.** Kurtarılabılır hücrelerde boş kalma oranı %28,3. Kural hata vermedi, uyarmadı, sadece boşluk üretti. İzlenmezse temiz görünen ama delik deşik bir tablo çıkar.
- Bazen güvenle yanlış yazıyor.** Uydurma sayısı 11 → 31. Bozuk Türkçe karakterli hücrelerde yanlış değer oranı %33,8: Yağmur olduğu gibi geçti, çift bozulmuş Ä...Ä%eyma yarım onarılıp Äžeyma oldu.
- Tek bir görünmez karakter veri kaybettirir.** Hücre sonundaki \r satırları ikiye böldü. Sekme ve | ayraçlı satırlarla birlikte 123 sipariş tamamen kayboldu.
- Hâlâ çalışanlar da var.** Önek eşleşmesi yapan kurallar (Yurtici Krg, İstanbul/Sarıyer) ve sadece rakamları ayıklayan telefon kuralı yeni biçimlere de dayandı. Genel kurallar dayanıklı, özel kurallar kırılğan.

Pratik sonuç

Kural tabanlı bir hat kurduysanız doğruluğu kadar **boş hücre oranını, karantinaya düşen satır sayısını ve satır sayısı farkını** da izleyin. Bu üç sayı sessiz kırılmanın ilk işareti. Kuralın tanımadığı değerleri boş bırakmak yerine ayrıca raporlamak, yeni biçimleri erkenden görmenin en ucuz yolu.

Sen de dene

Her iki veri seti de açık. Kendi yöntemi iki sette de çalıştır ve düşüşü karşılaştır:

```
# 1. bölüm: bilinen hatalar
veri-temizle puanla benim_ciktim/
# 2. bölüm: sürpriz hatalar
veri-temizle puanla benim_ciktim2/ --gercek veri_seti_surpriz/gercek
```

Yöntemin bilinen hatalarda iyi, sürpriz hatalarda da iyiye gerçekten genelleşiyor demektir.

Kod, veri ve yöntem: github.com/sefa05/Claude-veri-temizleme- · Veri tamamen sentetiktir, gerçek kişilere ait değildir.